

Agentic Robot Control:

Agent 应如何参与机器人控制?

Tianlun HE

2026 年 9 月 3 日

摘要

通用 Agent 正逐渐具备理解视觉环境、记忆交互历史以及根据执行结果修正计划的能力。与此同时，机器人基础模型和视觉语言动作模型（VLA）正在提高可执行动作的生成能力，真实世界强化学习（RL）则为策略通过物理交互持续适应提供了路径。然而，如何把这些能力连接成一个可靠的机器人控制系统，仍然是一个开放问题。本 proposal 研究 Agentic Robot Control，即在开放世界推理 Agent、机器人 policy 和低层控制器之间分配控制权限。

本研究从一个保守但具有普适性的设置开始：Agent 在每个 episode 结束后读取完整执行轨迹，识别任务阶段、执行进度和失败起点，并为 policy 的 Critic 提供结构化监督。随后，研究同一套执行理解如何支持 policy 编排、重试与恢复，以及更进一步的空间 action target 生成。实验面向装备双 Revo2 灵巧手的 Unitree G1 人形机器人，以冻结的 GR00T 作为基础 policy，并通过真实世界 RL 检验 Agent 产生的执行理解能否在固定交互预算下提高策略适应效率和任务可靠性。

1 研究愿景：从机器人 Policy 走向 Agentic Robot Control

机器人研究正在从单一任务 policy 走向能够在开放环境中执行长程任务的系统。一个 policy 可以把观测映射成动作，但可靠的物理行为还要求系统记住已经发生的事情，理解当前处于哪个任务阶段，区分真实进展和表面运动，并在执行出错时决定如何处理。对于人形机器人灵巧操作，这些要求更加突出，因为接触、平衡、身体运动和灵巧手之间存在紧密耦合。

因此，核心问题不只是语言模型能不能控制机器人，而是：

Agent 应在机器人控制系统中承担什么角色？通过什么接口，它对世界的理解才能真正改善物理执行？

本 proposal 将 Agent 的参与理解作为一种跨时间尺度的控制权限分配。在任务尺度上，Agent 解释指令、分解目标并维护交互历史；在执行尺度上，Agent 可以选择 policy、组合 policy，或产生 waypoint、visual prompt 和 action chunk 等空间表示；在学习尺度上，Agent 读取完整轨迹并解释发生了什么，帮助 policy 从真实交互中学习。

Agent 因此不是低层控制器的替代品，而是通过逐步开放的接口进入控制闭环：

理解执行 → 监督 policy 学习 → 编排 policy → 生成可执行目标。

这样的分阶段设计使研究既有前景又可验证。第一阶段检验 Agent 是否能可靠理解物理执行；第二阶段检验这种理解是否能改善 policy 学习；后续阶段再研究 Agent 是否能够在运行时选择、重试和组合 policy，以及最终生成动作目标。即使早期阶段得到负结果，也能明确指出当前 Agent 不适合获得哪一级控制权限，从而为后续系统设计提供可证伪的边界。

2 相关工作

相关工作按照 Agent 进入机器人控制系统所需的能力组织，而不是简单罗列模型名称。它们共同构成一条从世界理解、控制接口到物理执行和真实交互学习的能力链。

2.1 VISTA：对交互世界建立可查询的持续理解

VISTA 研究通用多模态模型如何在陌生交互环境中推理，并保留过去观测形成无损视觉记忆。它结合原始视觉输入、自由形式推理、主动视觉检查和持续交互历史，在视觉游戏中验证了长时程探索能力。

VISTA 的实验对象不是机器人，但它触及 Agentic Control 的一个基础要求：一次决策应该依赖此前发生的事情，而不只是当前帧。对于人形操作，这意味着把 episode 表示为动作、观测和状态变化的序列，让 Agent 可以在事后查询轨迹并定位进度与失败。

出处。 Qiushi Han, Keya Hu, Linlu Qiu, Cathy Wu, Kaiming He, *VISTA: A Visual Harness for Reasoning in an Interactive World*, MIT 官方项目页, 2026; 尚未核实正式同行评审 venue。
<https://vista-research.github.io/>

2.2 Claude Plays Robotics：控制接口决定能力能否落地

Claude Plays Robotics 比较了通用模型连接机器人时的多种方式，包括低层 torque、程序化控制器、从零开始的 RL，以及向预训练机器人 policy 提供高层指令。研究显示，同一个 Agent 在不同控制接口下可能呈现完全不同的机器人能力。对于高自由度机器人，高层 policy 接口比直接控制关节更加现实。

这项工作把问题从“模型是否足够聪明”转化为“Agent 应该控制什么”。它支持本 proposal 的权限分配观点，但并不意味着通用语言模型已经能够可靠地直接控制 humanoid。

出处。 Shmuel Berman, Michael Ilie, Jia Deng, Daniel Freeman, *Claude Plays Robotics*, Anthropic Research Report, 2026; 非同行评审报告。<https://www.anthropic.com/research/claude-plays-robotics>

2.3 Harness VLA: 用 Agent 编排冻结的 VLA

Harness VLA 将 frozen VLA 视为可重试的局部接触原语，把语义重新定位、staging、任务组织和失败恢复交给 Agentic Harness，而让 VLA 继续负责接触丰富的局部操作。

这一方向展示了介于单一 VLA 和直接 Agent 控制之间的中间路线：Agent 不取代 policy，而是通过编排和重试扩大预训练 policy 的有效工作范围。尚未解决的问题是，Harness 观察到的执行历史能否进一步转化为可学习的 Critic supervision，而不只是用于运行时重试。

出处。 Yixian Zhang 等, *Harness VLA: Steering Frozen VLAs into Reliable Manipulation Primitives via Memory-Guided Agents*, arXiv:2607.08448, 2026; arXiv preprint. <https://arxiv.org/abs/2607.08448>

2.4 VIA: Agent 生成空间控制目标

VIA 将机器人操作重新表述为 Agentic Visual Interface task。通用视觉 Agent 观察三维界面，发出直观的空间命令，读取结果并继续修正计划。它说明，在合适的空间接口下，Agent 不需要专门的机器人微调，也可以参与目标选择和闭环修正。

VIA 主要验证准静态操作和空间目标层面的控制，因此还不能直接说明 Agent 能否处理高速、接触丰富和全身协调的动作执行。它为本 proposal 提供的是“Agent 可以生成控制目标”的早期证据。

出处。 Hengyuan Hu、Priya Sundareshan、Jensen Gao、Dorsa Sadigh, *VIA: Visual Interface Agent for Robot Control*, arXiv:2607.11119, 2026; arXiv preprint. <https://arxiv.org/abs/2607.11119>

2.5 VP-VLA: 用 Visual Prompt 连接 Agent 与 VLA

VP-VLA 采用双系统结构：System 2 负责理解指令、分解任务并生成 crosshair、bounding box 等结构化 visual prompt，System 1 VLA 再依据这些提示执行动作。

与 VIA 相比，VP-VLA 更明确地研究 Agent 与 policy 之间的中间表示。Agent 不一定要输出最终动作，也可以输出一种能够约束和引导 VLA 的空间意图。这为 DexbotRL 提供了 visual prompt、waypoint 和 action chunk 等多种接口选择。

出处。 Zixuan Wang 等, *VP-VLA: Visual Prompting as an Interface for Vision-Language-Action Models*, arXiv:2603.22003, 2026; arXiv preprint. <https://arxiv.org/abs/2603.22003>

2.6 GR00T: 提供可被 Agent 调用的基础执行能力

GR00T N1 是面向通用的人形机器人的开放基础模型。它结合视觉语言理解和动作生成模块，并利用真实机器人轨迹、人类视频、仿真数据和合成数据学习通用动作先验。

在本 proposal 中, GR00T 代表执行侧的能力: 它适合处理连续动作、身体协调和局部物理执行, 而 Agent 负责任务级推理和执行结果分析。GR00T 本身并不解决长期记忆、失败解释、任务编排和真实世界在线适应, 因此更适合作为 Agent 可以调用、监督和修正的基础 policy。

出处。 NVIDIA、Johan Bjorck 等, *GR00T N1: An Open Foundation Model for Generalist Humanoid Robots*, arXiv:2503.14734, 2025; NVIDIA technical report / arXiv preprint. <https://arxiv.org/abs/2503.14734>

2.7 RL Token: 让基础 VLA 从真实交互中继续适应

RL Token 研究如何通过紧凑的强化学习接口适应预训练 VLA。方法暴露一个 RL token, 训练小型 actor-critic head, 同时通过 anchor 保留原始 VLA 的行为先验。

这说明大型 VLA 可以在有限真实交互下改善速度、精度和任务特定表现。但高效更新 policy 并不能自动解释 episode 为什么失败。DexbotRL 希望把 Agent 对阶段、进度和失败的理解作为结构化 Critic supervision, 补上这一环节。

出处。 Charles Xu、Jost Tobias Springenberg、Michael Equi 等, *RL Token: Bootstrapping Online RL with Vision-Language-Action Models*, arXiv:2604.23073, 2026; arXiv preprint. <https://arxiv.org/abs/2604.23073>

2.8 RoboReward: 从机器人视频中学习通用奖励

RoboReward 构建跨任务、跨 embodiment 的视觉语言奖励数据, 并使用 counterfactual negative、near-miss 和 temporal clipping 增加失败及部分完成样本。它的目标是减少对昂贵人工奖励标注和脆弱手工目标的依赖, 让模型能够从机器人视频中判断任务进展。

RoboReward 是本项目必须覆盖的强 reward baseline。但 DexbotRL 的初始目标不是让 Agent 直接替换环境奖励, 而是让 Agent 输出阶段、进度、failure onset 和失败类型, 再通过隔离的 Critic auxiliary branch 进入学习系统。

出处。 Tony Lee、Andrew Wagenmaker、Karl Pertsch 等, *RoboReward: General-Purpose Vision-Language Reward Models for Robotics*, arXiv:2601.00675, 2026; arXiv preprint. <https://arxiv.org/abs/2601.00675>

2.9 DenseReward: 通过失败合成提供稠密过程信号

DenseReward 在仿真中合成物理上合理的失败轨迹, 学习 frame-level reward 和 progress predictor, 并将其用于 MPC 或 RL。它解决了终点奖励过于稀疏的问题, 使系统能够估计轨迹中每个时间点的完成程度。

DenseReward 与 RoboReward 分别代表失败合成和视觉语言奖励两类路线。DexbotRL 将把它们作为对照, 比较自动学习的 scalar progress 与 Agent 对完整 episode 的结构化、带证据

解释的理解。

出处。 Yu Fang、Wanxi Dong、Jiaqi Liu 等, *DenseReward: Dense Reward Learning via Failure Synthesis for Robotic Manipulation*, arXiv:2607.13033, 2026; arXiv preprint. <https://arxiv.org/abs/2607.13033>

2.10 相关工作的综合判断

上述工作分别覆盖持续世界理解、控制接口设计、policy 编排、空间 action representation、人形基础 policy、真实世界适应和自动 reward learning。它们共同说明, Agent 参与机器人控制是一个有前景的方向, 但仍缺少一条经过系统实验验证的完整路径:

完整执行轨迹 → Agent 理解阶段、进度和 failure onset → 结构化 Critic supervision
→ 真实世界 policy adaptation → 运行时控制权限提升。

本 proposal 研究的正是这座桥梁。

3 核心问题

1. **执行理解:** Agent 能否从完整的多模态机器人轨迹中可靠识别任务阶段、进度和失败起点?
2. **学习价值:** 在相同真实交互预算下, 这种结构化理解能否改善 Critic 估计和 policy 适应, 相比 TD-only 与 scalar reward 基线是否具有可归因的增益?
3. **控制权限:** policy selection、retry/recovery、visual prompt、waypoint 和 action chunk 中, 哪一种接口能让 Agent 改善执行, 同时保留低层控制器的稳定性?

这三个问题构成一个递进的研究计划, 而不是三个互不相关的项目: 先验证 Agent 是否理解执行, 再验证这种理解是否对学习有用, 最后再研究它如何进入运行时控制。

4 研究计划

4.1 阶段一: Agent Hindsight 与 Critic 监督

第一阶段将 Agent 推理与高频控制环路分开。冻结的 GR00T policy 在装备双 Revo2 灵巧手的 Unitree G1 上执行 episode。episode 结束后, 异步多模态 Agent 读取同步的视觉观测、本体状态、reference action、executed action 以及可用触觉证据, 生成带时间定位和证据引用的阶段、进度、失败起点与置信度记录。

确定性编译器将这些记录转化为 Critic 的 auxiliary target。环境 reward、Bellman target 和 Actor 的 action contract 保持不变。这样, 第一组实验可以清楚回答: 提升是否来自额外的执行理解, 而不是来自改变动作空间或允许 Agent 在 rollout 中直接干预。

4.2 阶段二：真实世界 Policy Adaptation

第二阶段将结构化监督接入真实世界 RL。基础 policy 保持冻结，RL Token 或同类紧凑表示支持轻量级 actor-critic 更新。主要比较包括 TD-only、scalar VLM reward、dense progress reward 和结构化 Agent-supervised Critic。

评测将使用成对初始状态、固定训练预算、多个 seed（在资源允许时）和 held-out task instance。主要指标包括任务成功率、终止类型分布、执行进度和恢复行为。训练完成本身不被视为策略有效性的证据。

4.3 阶段三：运行时 Agent-Policy 控制

当执行理解和学习价值得到验证后，同一套任务状态接口可以进入运行时。Agent 可以选择 policy、触发重试、组合多个 policy，或向 VLA 传递空间目标。

Harness VLA、VIA 和 VP-VLA 分别提供 policy 编排、直接空间工具和 visual prompt 三种接口模板。本项目将根据任务时长、接触丰富度、推理延迟和安全要求比较这些接口，而不预设某一种抽象适合所有任务。

4.4 长期方向：Agent-Policy-World 闭环

长期目标是形成一个闭环系统：Agent 维护任务级世界模型，基础 policy 生成可执行动作，真实交互同时更新 policy 和 Agent 对任务的理解。本 proposal 不预设 Agent 会取代 policy，而是研究在保持可靠物理执行的前提下，Agent 可以获得多大程度的控制权限。

5 数据、评测与资源

目标平台是装备双 Revo2 灵巧手的 Unitree G1 人形机器人。当前 proposal 采用的完整动作表示为：64 维 SONIC body component，加上左右手各 6 维动作，总计 76 维。软件栈以冻结 GR00T base policy 和 RLinf 风格的真实世界强化学习为基础。

训练数据将结合已有机器人示范、仿真轨迹和真实交互 episode。数据转换和过滤产生版本化派生数据，原始数据保持不变。评测将区分技术资格、development signal 和 efficacy result。特别是，Agent 标注流水线成功运行或训练任务成功恢复，都不能在没有匹配评测分母的情况下被写成 policy improvement。

项目需要三类资源：第一，人形机器人和灵巧手，用于受控真实交互；第二，仿真与 replay 基础设施，用于安全消融和轨迹分析；第三，GPU 资源，用于冻结 policy inference、异步 Agent 分析和 actor-critic 训练。具体 GPU 数量和训练预算将在对 GR00T checkpoint、Agent 模型和 rollout 吞吐完成 profiling 后固定，本 proposal 不在测量前虚构硬件数字。

6 预期意义与可行性

该方向具有前景，主要有三个原因。第一，它建立在互补的现有进展之上，而不要求从零训练新的基础模型：VISTA 和相关 Agent 系统提供记忆与执行理解的设计启发，GR00T 提供人形动作先验，RL Token 提供有限真实交互下的适应路径。

第二，研究计划包含一个较早且可证伪的里程碑。如果结构化 Agent 监督不能在受控接口下改善 Critic 学习，项目可以在尝试直接 Agent 控制之前停止或修改方案。第三，一旦执行理解接口成立，它可以支持 policy 编排、失败恢复、空间 prompting 和 action-target generation 等多条后续路线，而不必过早把整个项目锁定在一种控制抽象上。

预期贡献包括：

1. 将 Agent 参与机器人控制形式化为任务、执行和学习三个时间尺度上的控制权限分配；
2. 构建一种把完整物理轨迹转化为结构化、时间对齐监督的 Agent-to-Critic 接口；
3. 在真实人形机器人上，受控评估这种监督是否能够改善冻结基础 policy 的适应；
4. 系统比较 Agent 编排 policy 与生成可执行空间目标的不同运行时接口。

7 时间计划

第一年： 建立轨迹 schema、Agent qualification protocol 和 Critic-supervision baseline，在仿真与 replay 中完成初步验证。

第二年： 开展受控真实世界 RL 实验，比较结构化监督、scalar reward 和 dense-progress baseline。

第三年： 研究运行时 policy 编排、重试与恢复，以及 visual prompt、waypoint 等中间空间接口。

第四年： 整合最有效的接口，形成 Agent-Policy-World 系统，并评估跨任务和跨 embodiment 的迁移能力。

参考文献

- [1] Q. Han, K. Hu, L. Qiu, C. Wu, and K. He. VISTA: A Visual Harness for Reasoning in an Interactive World. MIT project page, 2026. <https://vista-research.github.io/>
- [2] S. Berman, M. Ilie, J. Deng, and D. Freeman. Claude Plays Robotics. Anthropic Research Report, 2026. <https://www.anthropic.com/research/claude-plays-robotics>
- [3] Y. Zhang et al. Harness VLA: Steering Frozen VLAs into Reliable Manipulation Primitives via Memory-Guided Agents. arXiv:2607.08448, 2026. <https://arxiv.org/abs/2607.08448>

- [4] H. Hu, P. Sundaresan, J. Gao, and D. Sadigh. VIA: Visual Interface Agent for Robot Control. arXiv:2607.11119, 2026. <https://arxiv.org/abs/2607.11119>
- [5] Z. Wang et al. VP-VLA: Visual Prompting as an Interface for Vision-Language-Action Models. arXiv:2603.22003, 2026. <https://arxiv.org/abs/2603.22003>
- [6] NVIDIA, J. Bjorck et al. GR00T N1: An Open Foundation Model for Generalist Humanoid Robots. arXiv:2503.14734, 2025. <https://arxiv.org/abs/2503.14734>
- [7] C. Xu, J. T. Springenberg, M. Equi et al. RL Token: Bootstrapping Online RL with Vision-Language-Action Models. arXiv:2604.23073, 2026. <https://arxiv.org/abs/2604.23073>
- [8] T. Lee, A. Wagenmaker, K. Pertsch et al. RoboReward: General-Purpose Vision-Language Reward Models for Robotics. arXiv:2601.00675, 2026. <https://arxiv.org/abs/2601.00675>
- [9] Y. Fang, W. Dong, J. Liu et al. DenseReward: Dense Reward Learning via Failure Synthesis for Robotic Manipulation. arXiv:2607.13033, 2026. <https://arxiv.org/abs/2607.13033>