

DexbotRL: Agent 监督的真机强化学习

面向人形机器人灵巧操作

何天伦 (Tianlun HE)

摘要

视觉语言动作模型 (VLA) 与世界动作模型 (WAM) 正在分别提升机器人的通用动作生成能力, 以及对环境变化和动作后果的建模能力; 真机强化学习则使策略能够通过真实交互继续适配。然而, 这些能力仍不足以保证机器人在多阶段、接触密集任务中的可靠执行。此类任务不仅要求机器人生成动作, 还要求系统持续判断任务进程, 确认动作是否带来实际进展, 识别失败何时开始, 并将执行结果用于后续策略学习。这些问题也使 Agent 如何参与机器人控制成为一个值得进一步研究的方向。本文关注两种可能的系统形态: 由 Agent 在任务层控制和组织已有 policy, 或由 Agent 自身生成 action chunk、末端目标等可执行动作表示。两种形态可能适用于不同任务和控制时间尺度, 其共同前提是 Agent 能够理解实际执行过程。DexbotRL 以这一前提作为当前研究切入点。

这一方向当前可以从 Agent 与 policy 在不同时间尺度上的训练分工开始验证。policy 在控制周期内负责机器人动作执行, 真机 RL 利用真实交互更新策略; Agent 则在每个 episode 结束后分析完整轨迹, 将任务阶段、执行进展和失败起点转化为 Critic 的辅助监督。

作为对上述训练时分工的具体验证, DexbotRL 面向 Unitree G1 与双 Revo2 灵巧手开展真机强化学习。系统以冻结的 GR00T 作为多任务 Base, 以 RL Token 构造强化学习状态, 并通过任务特定的 Actor-Critic 学习完整 76D 动作。每个 episode 结束后, 异步多模态 Agent 读取视频、本体状态、参考动作、实际动作和可用触觉证据, 生成带时间定位、证据引用和置信度的阶段、进展与失败起点监督, 再由确定性程序编译为 Critic 的辅助学习目标; 环境奖励和 TD target 保持不变。项目检验的核心假设是: Agent 对完整轨迹的事后理解能否被蒸馏为 Critic 对动作后果的事前预测, 并在固定真机交互预算下提高策略的学习效率与任务可靠性。

1. 研究愿景: Agent 与机器人控制的未来

面向多阶段、接触密集的真机任务, Agent 参与机器人控制可能形成两种不同的系统形态。第一种是由 Agent 控制和组织已有 policy, 第二种是由 Agent 直接生成机器人动作。两者的区别不在于是否保留低层控制器, 而在于执行过程中的动作决策由哪一层产生: 前者将 Agent 置于 policy 之上, 由其决定调用什么能力以及如何组织任务; 后者则由 Agent 自身生成 action chunk、末端目标或其他可执行动作表示。这两种形态并非必然前后替代, 也可能分别适用于不同任务, 并在同一系统的不同时间尺度上长期共存。

在第一种形态中, Agent 根据任务目标和执行反馈维护任务状态, 选择、调用或切换 policy, 并在执行停滞或失败时决定继续、重试或重新规划; policy 与低层控制器负责高频、接触密集的稳定执行。Agent 输出的是 subgoal、policy 调用和流程决策, 而不是机器人关节动作。Claude Plays Robotics 对多种控制接口的比较为这种分工提供了直接依据: 通用模型借助预训练 policy 进行高层控制时明

显更为有效，而高自由度机器人的直接低层控制仍然困难。其实验估计 Go2 的实时低层控制约需 83 Hz，而当时的非推理模型调用仅约 0.2–0.4 Hz，二者仍相差约两个数量级 [1]。因此，由 Agent 控制 policy 是当前更具可行性的系统路线。

在第二种形态中，Agent 不再只选择已有 policy，而是根据视觉、机器人状态和执行反馈直接产生机器人下一步的动作表示。这里的“直接控制”并不意味着绕过伺服器、全身控制器和安全约束，而是指动作目标本身由 Agent 生成。VIA 已经展示了这一方向的早期形态：通用视觉 Agent 在没有机器人专项微调的情况下，通过由 RGB-D 场景和相机画面组成的 3D 界面闭环生成 6D 末端 waypoint，再由 PI 控制器完成轨迹执行。使用 Fable 5 时，该系统以最小任务提示在三项 LIBERO-Goal 任务上达到 96.7% 成功率，并在由七块积木组成的长程彩虹排列任务上达到 100% [2]。这些结果仍限于准静态仿真任务，但说明通用模型的感知、推理和纠错能力已经可以通过合适接口转化为机器人控制目标。

第二种形态也受到推理基础设施进展的推动。DeepSeek 的 FlashMLA 针对模型推理中的多头潜在注意力计算进行优化，其更新版本在 H800 上将计算受限场景的性能提高 5%–15%，并达到最高 660 TFLOPS [3]。这些指标衡量的是特定推理内核，而不是完整 Agent 的端到端响应时间，也不能直接等同于机器人控制频率；但它说明支撑大模型推理的计算开销仍有显著优化空间，为 Agent 参与更短时间尺度的决策提供了工程基础。Agent 直接生成动作能否从准静态操作扩展到动态、接触密集的真机任务，仍需在完整闭环中验证推理延迟、动作精度、反馈频率和安全边界。

DexbotRL 从两种形态共同依赖的执行理解问题开始：Agent 在 episode 结束后分析完整轨迹，将阶段、进展和失败信息转化为 Critic 的辅助监督，以检验 Agent 对执行过程的理解能否真正改善 policy 学习。若这一机制成立，同一套任务状态与执行证据接口可以进一步支持两类研究：一类是在运行时选择 policy、触发重试和组织技能，另一类是直接生成动作并根据执行反馈进行修正。因此，DexbotRL 首先回答执行理解能否反馈给学习系统，再以实验结果为基础研究 Agent 应当以何种方式参与机器人控制。

2. 研究背景与领域判断

机器人学习近期在基础模型、系统构建、强化学习和数据生成方面同时取得了进展，但这些方向并不是彼此独立的。基础模型决定系统能够生成什么，系统支撑层决定模型能力如何进入真实执行，强化学习负责利用交互修正策略，而数据决定这些能力可以覆盖哪些任务与本体。对于长程、接触密集的人形操作，任何一个环节的缺失都会限制最终的真机性能。

2.1 VLA 与 WAM：基础模型能力尚未转化为复杂任务可靠性

VLA 与 WAM 正从不同路径扩展机器人基础模型的能力。VLA 学习视觉、语言和机器人状态到动作的映射 [4,5]，WAM 则从视频与动作序列中建模环境如何随时间和动作发生变化 [6,7]。尽管建模目标不同，二者都在扩大模型能够覆盖的任务、本体与运动模式。评价这些进展的关键，不只是模型能否生成更合理的动作或未来，而是这种能力能否在复杂任务中持续转化为稳定的执行结果。

现有工作已经显示出明确的模型能力增益。GR00T N1.7 在双臂、半人形和人形机器人数据上训练，并使用超过 20,000 小时的第一视角人类视频，使同一模型能够面向不同本体进行后训练 [8]。在工程接口上，embodiment tag 用于选择对应的状态、动作与归一化配置；官方文档还提供了 Unitree

G1 与 SONIC 全身控制器的微调和部署流程 [9]。MotionWAM 进一步使用视频世界模型的动力学特征和统一的 motion latent 表示全身动作。在示范数据、动作空间和 SONIC 控制接口保持一致的九项 Unitree G1 真机任务中, MotionWAM 的平均成功率为 76.1%, GR00T N1.7 为 43.9% [10]。这些结果说明, 跨本体预训练、视频动力学先验和全身动作表达正在提高人形机器人的任务能力。

但平均性能的提高尚不足以证明复杂任务已经具备可靠性。HumanoidArena 在七项需要足部参与的仿真人形任务中采用统一的 40D 动作接口; 在 SONIC tracker 下, 最强 Diffusion Policy 在人-物交互 (HOI) 和人-场景交互 (HSI) 上的平均成功率分别为 52.22% 和 65.83%, VLA 类模型 $\pi_{0.5}$ 分别为 41.67% 和 58.33%; 更换底层 tracker 后, 性能还会显著下降 [11]。该基准不能与 MotionWAM 的真机结果直接比较, 但它表明模型表现仍然对任务分布、动作接口和低层控制器高度敏感。在长程任务中, 阶段切换与误差累积仍需专门处理: Long-VLA 显式引入阶段感知机制, LiLo-VLA 则依赖动态重规划和失败恢复 [12,13]。因此, VLA 与 WAM 已经提供了更强的动作与表征基础, 但尚未形成能够可靠完成复杂任务的通用方案。

2.2 Agent-Policy 接口: 从模型能力到可靠执行

基础模型能否转化为真机能力, 不仅取决于模型本身, 也取决于 Agent 以何种接口参与控制。Anthropic 对不同机器人本体和控制方式的比较表明, 同一模型在直接输出低层动作、编写控制器和调用预训练 policy 时表现差异显著; 对于高自由度机器人, 借助预训练 policy 的高层控制更为有效, 而 Agent 对已有 VLA 动作的不必要干预也可能降低性能 [1]。因此, 关键不是用 Agent 替代 policy, 而是明确二者之间的委托、干预和反馈机制。

VIA 展示了另一种接口形式: 通用 Agent 通过视觉 3D 界面设置 6D 末端 waypoint, 具体轨迹由 PI 控制器执行。Table 5 由此能够零样本完成多类仿真桌面操作, 但在要求毫米级精度的 T-block 任务上仍明显受限, 其推理速度和成本也使其主要适用于准静态任务 [2]。这表明 Agent 已经能够参与动作目标生成, 但其实际能力仍由控制抽象、任务动力学和低层执行器共同决定。

本文将承载这种分工的运行机制统称为 Harness。Harness VLA 将冻结的 VLA 封装为可重试的局部接触原语, 由 Agent 负责语义定位、执行阶段组织、预接触姿态调整和失败恢复, 并在不更新 VLA 参数的情况下提高了扰动任务中的成功率 [14]。VISTA 虽然面向交互式视觉游戏, 但其逐帧保存视觉观测、动作历史和可修订任务笔记, 并允许 Agent 主动回看历史证据 [15]。这些工作说明, 可靠的接口不仅需要组织 policy 调用, 还需要保留可查询的执行历史, 使 Agent 能够根据执行结果决定继续、重试或终止。

由此形成了一种近期更可行的分工: 低频 Agent 负责维护任务状态、组织 policy 和处理失败, 高频 policy 与控制器负责接触密集动作的稳定执行。在上述工作中, Agent 主要承担既有能力的运行时编排和执行恢复; 将 Agent 对完整轨迹的理解转化为 Critic 辅助监督, 并进一步影响 policy 学习, 在上述系统中尚未得到系统验证 [1,2,14,15]。要使机器人在具体物体和接触条件下继续改进, 还需要把这种执行理解与真机强化学习连接起来。

2.3 真机强化学习: 高维人形控制中的探索与信用分配

真机强化学习能够利用真实接触修正预训练策略或模仿学习未能覆盖的物体差异、摩擦条件和动力学误差。已有研究首先在固定基座机械臂上证明了这一路径的可行性。ConRFT 以预训练 VLA 为起点, 结合离线行为克隆、Q 学习、在线一致性策略和人工干预 [16]; HIL-SERL 则利用示范与在

线人工纠错，将训练数据集中在策略容易失败的区域 [17]。这些方法说明，在较强策略先验和有限人工纠错的支持下，真实交互可以用于针对性地改善策略。

但这一结论不能直接外推到人形机器人与灵巧手。ROVE 是近期将基于真实经验的 VLA 后训练扩展到人形灵巧操作的一项代表性工作，通过全身人工干预、混合质量轨迹和 Optimistic Value Estimation 完成桌面任务学习 [18]。它提供了初步可行性证据，也反映了当前方法对人工纠错和数据筛选的依赖。与固定机械臂相比，人形机器人的动作扰动会同时影响身体平衡、双臂协调和手部接触；在上述真机工作所覆盖的范围内，高维全身 Actor 在不同任务和接触模式中的探索仍缺少系统比较 [16–18]。

探索决定系统能够收集什么数据，反馈形式则决定 Critic 能够从这些数据中学到什么。VLAC 学习过程奖励并将其用于 Critic 与策略优化 [19]；RoboReward 通过反事实重标注和时间裁剪构造失败、近失与部分进展样本，并训练用于真机 RL 的视觉语言奖励模型 [20]；DenseReward 则从合成失败轨迹中学习帧级任务进展，并将稠密反馈用于真机策略优化 [21]。这些工作将监督从最终成功标签扩展到任务级或帧级的奖励与进展信号，但没有显式将执行监督分解为任务阶段、进展方向和失败起点。对于多阶段人形任务，这类结构化目标可以帮助 Critic 更准确地判断中间动作对后续结果的影响。

基于上述限制，DexbotRL 采用两个相互对应的设计：由多任务 Base 提供跨任务动作先验，再针对每项任务分别进行真机 RL，以避免同一个在线 Actor 同时探索多种高维接触模式；同时由 Agent 从完整轨迹中提取阶段、局部进展和失败起点，为 Critic 提供结构化辅助监督。Agent 输出不替代环境奖励，也不修改 TD 目标，而是用于改善 Critic 的动作排序与信用分配。前者约束真机探索，后者补充执行过程监督；而多任务 Base 能够提供怎样的先验，又进一步取决于人形机器人数据的覆盖范围和可执行性。

2.4 人形机器人数据：仿真生成快速发展，灵巧操作仍难以规模化

人形机器人仿真数据正在从人工搭建场景和规则脚本转向模型驱动自动生成。SAGE 利用 Agent 协调场景生成器与视觉、物理 Critic，并通过抓取姿态预测、逆运动学和导航规划生成示范，但其动作生成主要面向 Franka 抓放与移动操作 [22]。GRAIL 结合三维资产、视频生成先验和动作重定向，生成超过 20,000 条人形移动操作序列并完成 Unitree G1 的仿真到真机验证，但手部仍采用映射到预定义关节配置的二值开合信号 [23]。这些工作表明，场景构建和全身运动数据已经出现明确的规模化趋势。

灵巧操作数据也在快速发展。HumanoidGen 通过原子操作、空间标注以及 LLM 推理与搜索生成 26D 双臂和双手任务，但主要集中于桌面场景，资产库外的新类别和新的原子操作类型仍需人工标注 [24]。Do As I Do 从单目人类视频中恢复手物交互，并将其重定向为多指机器人动作；其重建与重定向集中于手-物交互，不覆盖完整场景或人形全身运动 [25]。综合上述工作，所引用的方法分别覆盖了场景生成、全身轨迹和局部手物交互，但没有一条管线同时提供连续多指动作、可信接触动力学、全身协调和真机可执行性 [22–25]。在这些管线中，接触行为的生成仍较多依赖预定义原子操作、人工标注和动作重定向规则，因而难以低成本地批量扩展。

这一缺口并不否定仿真数据的价值，而是明确了生成数据与真机学习的分工。生成数据适合提供任务分布、动作先验和策略初始化，真机强化学习则利用真实交互修正摩擦、滑移、柔顺性和控制误差。因此，在多任务 Base 上开展面向具体灵巧任务的真机 RL，是连接规模化仿真数据与可靠

真实执行的关键环节，也构成 DexbotRL 的直接研究动机。

3. DexbotRL：研究方案与实验设计

3.1 研究问题与核心假设

DexbotRL 研究多任务机器人基础模型在高自由度真机任务中的单任务适配问题。预训练 Base 能够提供跨任务的视觉语言表征和动作先验，但难以直接适应具体物体、接触条件和机器人动力学；真机强化学习可以利用真实交互继续修正策略，却同时受到高维动作空间下探索成本高和稀疏回报下信用分配困难的限制。项目首先以“多任务 Base + 单任务 76D RL”建立基线系统，并将 Agent-Critic 辅助监督作为需要独立检验的核心变量。

核心研究问题是：在 Base、动作接口和真机交互预算保持一致的条件下，利用 Agent 从完整轨迹中提取的任务阶段、局部进展和失败起点信息，能否改善 Critic 对候选动作的排序与价值校准，并最终提高单任务策略的成功率和学习效率？实验仅改变 Critic 侧的监督形式，从而将 Agent 监督的作用与策略结构、动作空间和交互数据变化区分开来。

核心假设是，完整轨迹包含稀疏环境奖励未能显式表达的执行信息；将这些带有时间定位和证据约束的事后判断蒸馏到 Critic，可以增强其在动作执行前判断后续结果的能力。只有当“Agent 标签质量提高、Critic 排序与校准改善、固定真机预算下 policy 表现提升”这一证据链完整成立时，该假设才得到支持。




图 1: DexbotRL 方法总览。完整 episode 同时产生环境 TD 信号和 Agent 生成的执行级辅助监督；二者共同训练 Critic，并通过 Q 值梯度更新任务特定的 Actor。

3.2 策略基线：多任务 Base 上的单任务真机 RL

DexbotRL 将跨任务能力和任务内探索放在不同层级。冻结的 GR00T 作为所有任务共享的多任务 Base，提供视觉语言表征与参考动作；每个具体任务分别训练 RL Token 和 Actor-Critic，并使用各自的真机交互数据进行优化。这样的设计保留 Base 的通用先验，同时避免让同一个在线 Actor 在

多种接触模式之间共同探索，从而将有限的真实交互集中于当前任务。

RL Token 将 GR00T 表征转换为面向价值学习的紧凑状态 $z_{rl,t}$ 。Actor 结合该状态、机器人本体状态 p_t 和 GR00T 参考动作 a_t^{ref} ，生成实际执行的完整动作：

$$\begin{aligned} z_{rl,t} &= f_{\psi}\left(h_t^{GR00T}\right), \\ a_t &= \pi_{\theta}\left(z_{rl,t}, p_t, a_t^{ref}\right) = [a_t^{body}, a_t^{left}, a_t^{right}] \in \mathbb{R}^{76}, \\ a_t^{body} &\in \mathbb{R}^{64}, \quad a_t^{left}, a_t^{right} \in \mathbb{R}^6. \end{aligned}$$

其中，64D body latent 由全身控制器解码，左右两组 6D 动作分别控制两只 Revo2 灵巧手。参考动作只作为 Actor 的条件，最终执行动作由 Actor 在完整 76D 空间中直接生成，而不是仅对手部或 Base 动作施加局部 residual。这样可以保留身体姿态、双臂运动与手部接触之间的联合适配。

Critic 根据 $z_{rl,t}$ 、本体状态和候选动作估计长期回报，并以环境奖励、后继状态和终止信号构成的标准 TD 目标进行训练。由 GR00T、RL Token、完整动作 Actor 和 TD Critic 组成的系统定义了 DexbotRL 的任务 Baseline；后续 Agent 实验保持其状态接口、动作空间、Actor 结构和环境奖励不变，使性能差异能够归因于新增的 Critic 监督。

3.3 核心方法：基于完整轨迹的 Agent-Critic 辅助监督

标准的时序差分学习使用环境奖励、后继状态和终止信号定义价值目标，但这些信号难以完整描述多阶段任务中的执行过程。最终成功或失败不能直接说明机器人是否已经建立稳定接触、某个动作带来了进展还是退步，也不能指出一次可观察的失败最早出现在哪个区间。DexbotRL 因此将多模态 Agent 作为异步的轨迹分析教师，从已经完成的 episode 中提取标准 TD 目标未显式执行的执行级信息，而不让 Agent 重新定义任务奖励或参与当前 rollout。

Agent 由一个确定性的外层工作流进行编排。工作流规定轨迹分析、证据查询、结果复核和标签编译的执行顺序，并限制工具调用、重试和拒答条件；多模态模型只在规定的分析节点中作出判断，不能自行增加处理步骤、调用环境或控制机器人。具体模型、提示词、工具接口和输出版本在实验开始前固定，使同一 episode 的分析过程能够被记录和重放。该设计不依赖多个 Agent 之间的自由对话，而是使用一个受约束的多模态模型完成不同阶段的轨迹分析。

episode 结束后，确定性证据构建程序首先按照真实 action chunk 对齐视频、本体状态、GR00T 参考动作、实际执行动作、环境奖励、终止原因和可用触觉记录，并为每个时间区间建立统一索引。Agent 首先读取任务合同和完整轨迹的概览，再通过预先注册的只读接口查询相关视频片段、状态变化以及参考动作与实际动作之间的差异。因此，“使用完整轨迹”表示 Agent 可以根据需要访问整个 episode 的历史证据，而不是将全部原始视频和数值序列一次性输入模型。

任务合同规定可使用的任务阶段、阶段转换、成功条件和可观察失败事件。它首先在独立的轨迹集合上建立并经过人工复核，随后在正式标注前固定版本。Agent 在分析新的 episode 时只能使用已经确定的阶段和事件词表，不能为每条轨迹重新定义任务结构。分析过程首先定位可观察的状态变化和候选失败区间，随后通过独立的复核步骤检查视频、本体状态和动作证据是否一致；判断无法得到充分支持时，Agent 必须缩小时间范围、修改判断或拒绝标注。

对于每个 action chunk，Agent 判断三个与价值学习相关的问题：动作发出前处于哪个任务阶

段，该动作使任务前进、停滞还是退步，以及可观察失败是否在这一动作区间内开始。每项判断同时保留对应的时间范围、模态证据和置信信息；自然语言解释只用于审计和错误分析，不直接输入 Critic。三个字段可以独立拒答，例如 Agent 可以确定任务阶段，但在遮挡条件下无法判断是否发生滑移，从而只屏蔽无法确认的监督目标。

Agent 输出仍然是带有时间定位的语义判断，而不是奖励值或训练张量。确定性标签编译器根据 episode 标识和 action chunk 起点，将这些判断与 replay 中的状态-动作样本精确对齐。阶段判断被编译为阶段分类目标，前进、停滞和退步被编译为进展目标，失败起点则被编译为失败起点预测目标。只有经过证据复核的判断才进入训练；拒答、证据冲突或时间区间无法完整对齐的样本，通过独立的 mask 从相应辅助损失中排除。“没有检测到失败”也不会自动成为负样本，只有完整动作区间已经得到有效检查时，才能生成 failure-negative 标签。

三个辅助预测头与 Q 函数共享 Critic 的状态-动作表征。Critic 的训练目标为：

$$\mathcal{L}_{\text{critic}} = \mathcal{L}_{\text{TD}} + \lambda_s \mathcal{L}_{\text{stage}} + \lambda_p \mathcal{L}_{\text{progress}} + \lambda_f \mathcal{L}_{\text{failure}}.$$

其中， $\mathcal{L}_{\text{TD}}$ 仍然只由环境奖励、后继状态和终止信号计算；三个辅助损失分别训练阶段识别、动作进展判断和失败起点预测。每个辅助目标仅在对应该标签有效时计算，并根据经过复核和校准的标签可靠性进行加权。Agent 不直接决定损失权重，也不改变 Q 值表示环境长期回报的含义。

完整轨迹及动作执行后的结果只存在于离线教师侧。在线 Critic 仍只能访问动作执行前可获得的状态和候选动作，Actor 也不直接读取 Agent 标签，而是继续通过 Critic 的 Q 值更新。由此，Agent 对策略的影响被限制在一条明确的路径中：Agent 利用完整轨迹形成事后执行监督，Critic 将这些监督学习为对候选动作后果的事前判断，Actor 再通过 Q 值梯度获得改进。该方法最终检验的不是 Agent 能否解释一条已经完成的轨迹，而是这种轨迹理解能否改善 Critic 的信用分配，并进一步提高固定真机交互预算下的策略表现。

3.4 实验设计与分阶段验证

3.4.1 任务设置与主要评价终点

初始实验选择打开水瓶和操作空调遥控器，以覆盖两种互补的接触模式。打开水瓶要求机器人稳定瓶身并持续旋转瓶盖，主要检验双手协调、摩擦变化和滑移条件下的连续控制；操作遥控器要求机器人抓取并调整其姿态、定位目标按键并确认触发结果，主要检验小目标定位和离散的精细接触。两项任务共享同一个 GR00T Base，但分别训练单任务 Actor-Critic。

打开水瓶作为核心方法的主实验，操作遥控器用于检验结论能否迁移到不同的接触结构。主要评价终点是固定真机交互预算后的任务成功率：前者以瓶盖达到预定打开状态且瓶身保持稳定为成功，后者以指定按键被正确触发并产生预期状态变化为成功。实验开始前固定每种方法的交互步数、episode 数、评测回合数、独立训练重复次数和重置规则，并对任务成功率报告置信区间；学习曲线、交互与重置成本、失败类型和安全中止次数作为辅助指标。

3.4.2 基线系统资格验证

Agent-Critic 实验建立在已经通过资格验证的 76D 单任务 RL Baseline 上。Baseline 阶段依次比较四种设置：

设置	状态与策略接口	回答的问题
GR00T-Direct	直接执行 GR00T 参考动作	多任务 Base 能否直接完成任务
RL-Raw	直接使用 GR00T 表征训练 76D Actor-Critic	单任务真机 RL 是否带来适配收益
RL-Pool	使用与 RL Token 同宽度的无参数状态摘要	收益是否仅来自压缩和输入维度变化
RL-Token	使用可学习的 RL Token 训练 76D Actor-Critic	RL Token 是否提供可归因的表示增益

这一阶段只负责确定可靠的任务 Baseline，不承担 Agent 方法的主要结论。只有 76D Actor-Critic 在相同预算下相对 GR00T-Direct 表现出稳定改进，才进入 Agent-Critic 实验；RL Token 的独立贡献则根据其 与 RL-Raw 和 RL-Pool 的匹配比较单独报告。完成资格验证后，后续比较固定 Base checkpoint、状态接口、Actor 结构与初始化方式、动作空间和环境奖励。

3.4.3 Agent-Critic 核心对照

核心实验改变 Critic 的监督形式，并保持训练数据量、真机交互预算和其他训练设置一致。三种主要配置为：

设置	Critic 监督	对照目的
TD-only	环境奖励定义的标准 TD 目标	衡量任务 Baseline
One-shot	同一多模态模型一次性读取轨迹并生成标签	控制多模态模型本身带来的收益
Agent-Critic	证据查询、一致性复核、置信度与拒答组成的完整工作流	检验 Agent 工作流的独立作用

三种配置使用相同的 Critic backbone、初始化方式、replay 数据、更新预算和在线交互预算。TD-only 不启用辅助目标；One-shot 与 Agent-Critic 使用相同的辅助预测头和损失，二者仅在标签生成方式上不同。

三种配置首先在打开水瓶任务上进行完整比较；若 Agent-Critic 同时改善监督质量、Critic 指标和固定预算下的任务成功率，再在操作遥控器任务上比较 TD-only 与 Agent-Critic，以检验主要结论能否跨接触模式复现。阶段、进展和失败辅助目标的逐项移除，以及触觉作为 Agent 事后证据或 Critic 在线输入的两种作用，均作为次级消融，优先在仿真和离线阶段筛选，不与核心真机比较同时展开。

3.4.4 证据链与阶段门槛

方法评价沿着“监督-Critic-policy”的因果链展开。监督层在人工复核集上测量阶段、进展和失败标签的准确性、证据有效性、有效覆盖率与拒答质量；Critic 层测量动作排序、价值校准和失败起点预测；policy 层测量固定预算下的任务成功率和学习效率。只有前一层的改善能够传递到后一层，才将最终性能变化归因于 Agent-Critic 监督。

验证按照四个门槛推进。第一步在仿真中确认 76D 动作接口、RL Token 和辅助损失能够稳定

训练；第二步在固定的成功、失败与超时轨迹上开展离线 pilot，要求 Agent workflow 相对一次性标注提高标签质量，并改善 Critic 的动作排序或校准；第三步在打开水瓶任务上完成固定预算的真机核心实验；第四步在操作遥控器任务上复现主要比较。各阶段沿用一致的任务定义、轨迹格式和评价口径，但仿真与离线结果只用于筛选机制，最终结论以真机任务表现为准。

4. 项目可行性

DexbotRL 的方法由可独立验证的模块构成。GR00T 作为冻结的多任务 Base 提供表征和动作先验，下游只需针对具体任务训练 RL Token 与 Actor-Critic，避免在有限的真机数据上重新学习完整的视觉语言能力。Agent 监督则在 episode 结束后异步生成，不增加在线控制环路的推理延迟，也不改变环境奖励所定义的优化目标。表示学习、策略适配和 Critic 监督因此可以通过匹配对照分别评估，使每个模块的作用具有可归因性。

项目所需的实验链路由仿真环境、遥操作与数据采集管线、Unitree G1、双 Revo2 灵巧手以及 GPU 计算资源共同支撑。仿真环境用于快速筛选状态表示、动作接口和辅助监督目标；遥操作与数据管线用于组织成功、失败和超时轨迹，并保留视频、本体状态与执行动作等证据；真机平台则用于检验策略在真实接触、动力学误差和全身协调条件下的学习效果。这些环节能够共享统一的任务定义与轨迹格式，使离线分析得到的监督可以直接进入后续 Critic 训练和真机评测。

项目的主要不确定性来自高维真机探索、Agent 标签误差和仿真到真机迁移。高维探索通过多任务 Base 的动作先验、单任务 RL 和固定交互预算缩小搜索范围，并结合安全中止与失败记录控制真机代价；Agent 输出通过证据引用、置信度和拒答机制接受质量筛选，并仅作为 Critic 的辅助目标；仿真结果则通过独立的真机实验进行验证，不直接替代真实执行指标。由此，每一类风险都对应明确的对照、评价指标和验证阶段，使 DexbotRL 能够沿着从离线机制验证到真机闭环学习的路径逐步推进。

5. 预期贡献

这项研究预期形成三类贡献：

1. **方法方面：**研究一种由 Agent 生成、带有证据和时间定位的执行级监督，并检验它能否改善 VLA 基座上的真机 Actor-Critic 学习。
2. **系统方面：**建立 GR00T、RL Token、Critic 和 Agent 之间可复现的接口，在人形机器人与灵巧手任务上评估样本效率、任务性能和安全边界。
3. **认识方面：**进一步明确 Agent 在具身系统中的职责边界，回答哪些信息应进入 policy、哪些信息应进入 Critic，以及什么时候适合由 Agent 编排 policy 或直接输出控制。

从长远看，世界模型、policy 和 Agent 可以共同构成真实机器人闭环：世界模型预测可能的未来，Agent 理解目标与执行状态，并根据任务需要选择和组织 policy，或直接生成适当时间尺度上的动作目标；policy 与低层控制器则在需要时保证稳定的物理执行。DexbotRL 研究的是两种形态共同依赖的一环，即如何把对执行过程的理解反馈给学习系统。

参考文献

- [1] Berman et al., “Claude Plays Robotics,” Anthropic Research, 2026. [Online]. Available: <https://www.anthropic.com/research/claude-plays-robotics>. Accessed: Aug. 16, 2026.
- [2] Hu et al., “VIA: Visual Interface Agent for Robot Control,” *arXiv preprint arXiv:2607.11119*, 2026.
- [3] DeepSeek-AI, “FlashMLA: Efficient Multi-head Latent Attention Kernels,” GitHub repository, 2025. [Online]. Available: <https://github.com/deepseek-ai/FlashMLA>. Accessed: Aug. 16, 2026.
- [4] Bjorck et al., “GR00T N1: An Open Foundation Model for Generalist Humanoid Robots,” *arXiv preprint arXiv:2503.14734*, 2025.
- [5] Kim et al., “OpenVLA: An Open-Source Vision-Language-Action Model,” in *Proc. 8th Conf. Robot Learning (CoRL)*, PMLR, vol. 270, pp. 2679–2713, 2025.
- [6] Ye et al., “World Action Models are Zero-shot Policies,” *arXiv preprint arXiv:2602.15922*, 2026.
- [7] Gao et al., “DreamDojo: A Generalist Robot World Model from Large-Scale Human Videos,” in *Proc. 43rd Int. Conf. Machine Learning (ICML)*, PMLR, vol. 306, 2026. [Online]. Available: <https://arxiv.org/abs/2602.06949>. Accessed: Aug. 16, 2026.
- [8] NVIDIA, “NVIDIA Isaac GR00T N1.7: Open Reasoning VLA Model for Humanoid Robots,” Hugging Face Blog, 2026. [Online]. Available: <https://huggingface.co/blog/nvidia/gr00t-n1-7>. Accessed: Aug. 16, 2026.
- [9] NVIDIA GEAR Team, “VLA Workflow: Collect, Fine-tune, Deploy,” *GR00T-WholeBodyControl* documentation, 2026. [Online]. Available: https://nvlabs.github.io/GR00T-WholeBodyControl/tutorials/vla_workflow.html. Accessed: Aug. 16, 2026.
- [10] Zheng et al., “MotionWAM: Towards Foundation World Action Models for Real-Time Humanoid Loco-Manipulation,” *arXiv preprint arXiv:2606.09215*, 2026.
- [11] Wang et al., “HumanoidArena: Benchmarking Egocentric Hierarchical Whole-body Learning,” *arXiv preprint arXiv:2606.17833*, 2026.
- [12] Fan et al., “Long-VLA: Unleashing Long-Horizon Capability of Vision Language Action Model for Robot Manipulation,” *arXiv preprint arXiv:2508.19958*, 2025.
- [13] Yang et al., “LiLo-VLA: Compositional Long-Horizon Manipulation via Linked Object-Centric Policies,” *arXiv preprint arXiv:2602.21531*, 2026.
- [14] Zhang et al., “Harness VLA: Steering Frozen VLAs into Reliable Manipulation Primitives via Memory-Guided Agents,” *arXiv preprint arXiv:2607.08448*, 2026.
- [15] Han et al., “VISTA: A Visual Harness for Reasoning in an Interactive World,” Project website, 2026. [Online]. Available: <https://vista-research.github.io/>. Accessed: Aug. 16, 2026.
- [16] Chen et al., “ConRFT: A Reinforced Fine-tuning Method for VLA Models via Consistency Policy,” *arXiv preprint arXiv:2502.05450*, 2025.
- [17] Luo et al., “Precise and Dexterous Robotic Manipulation via Human-in-the-Loop Reinforcement Learning,” *arXiv preprint arXiv:2410.21845*, 2024.
- [18] Xiao et al., “ROVE: Unlocking Human Interventions for Humanoid Manipulation via Reinforcement Learning,” *arXiv preprint arXiv:2606.17011*, 2026.
- [19] Zhai et al., “A Vision-Language-Action-Critic Model for Robotic Real-World Reinforcement Learning,” *arXiv preprint arXiv:2509.15937*, 2025.
- [20] Lee et al., “RoboReward: General-Purpose Vision-Language Reward Models for Robotics,” *arXiv preprint arXiv:2601.00675*, 2026.
- [21] Fang et al., “DenseReward: Dense Reward Learning via Failure Synthesis for Robotic Manipulation,” *arXiv preprint arXiv:2607.13033*, 2026.
- [22] Xia et al., “SAGE: Scalable Agentic 3D Scene Generation for Embodied AI,” in *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR)*, pp. 22358–22368, 2026.

-
- [23] Xie et al., “GRAIL: Generating Humanoid Loco-Manipulation from 3D Assets and Video Priors,” *arXiv preprint arXiv:2606.05160*, 2026.
 - [24] Jing et al., “HumanoidGen: Data Generation for Bimanual Dexterous Manipulation via LLM Reasoning,” in *Advances in Neural Information Processing Systems*, vol. 38, 2025.
 - [25] Paliwal et al., “Do As I Do: Dexterous Manipulation Data from Everyday Human Videos,” *arXiv preprint arXiv:2606.19333*, 2026.